

Universidad Francisco de Vitoria

Grado en Business Analytics

Memoria de Análisis del Dato

Proyecto Pulso: análisis y predicción de la demanda en una empresa de electromedicina

Modelización predictiva de demanda para los productos más relevantes del negocio

Trabajo Fin de Grado

Alumno: Santiago Robles Peñamaría

Tutor: Rufino Prieto Alonso

Curso académico 2025-2026

Contenido

Índice orientativo.....	¡Error! Marcador no definido.
1. Introducción y problema analítico.....	4
2. Diagrama de flujo.....	5
3. Objetivos e hipótesis de trabajo.....	6
4. Marco teórico de los modelos empleados	6
4.1. Predicción de demanda en entornos empresariales	6
4.2. Baseline como referencia mínima	7
4.3. Ridge: modelo lineal regularizado.....	7
4.4. Random Forest como etapa intermedia de exploración.....	8
4.5. XGBoost como modelo final.....	8
4.6. Métricas de evaluación.....	8
5. Diseño metodológico y construcción de variables	9
Tabla 1. Resumen del diseño muestral y temporal.....	9
5.1. Variables predictoras utilizadas.....	10
Tabla 2. Estructura de las variables predictoras	10
6. Resultados del contraste entre modelos.....	10
Tabla 3. Comparación final de modelos.....	11
6.1. Lectura visual de la predicción mensual	11
6.2. Dispersión real vs. predicho	12
6.3. Importancia de variables.....	15
Tabla 4. Principales variables del modelo XGBoost.....	17
7. Interpretación por producto y discusión de resultados	17
Tabla 5. Métricas por producto del modelo XGBoost.....	18
8. Implicaciones de negocio y recomendaciones	18
8.1. Discusión crítica de los resultados y del comportamiento del error.....	19
8.2. Mejora relativa frente al baseline y lectura comparativa por modelos	19

8.3. Lectura del resultado desde compras y planificación.....	20
8.4. Escenario práctico de implantación del modelo.....	20
9. Limitaciones y líneas futuras.....	21
10. Conclusiones	22
11.Bibliografía.....	23
Anexo A. Resumen final de resultados clave.....	24
Anexo B. Resultados complementarios de la fase preliminar con Random Forest.....	25
Anexo C. Detalle ampliado del modelo final XGBoost	27

1. Introducción y problema analítico

Una vez obtenida una base mensual limpia y consistente, la siguiente pregunta natural del proyecto fue cómo anticipar la demanda futura de los productos más relevantes. El objetivo del análisis del dato no era simplemente comprobar que se podía ajustar un modelo estadístico, sino evaluar si el histórico reciente de cantidades y ventas contenía suficiente información para construir una predicción útil para la toma de decisiones empresariales. Esta utilidad se entiende en un sentido práctico, que es anticipar necesidades de aprovisionamiento, identificar productos sensibles a cambios de ritmo y apoyar decisiones comerciales con una base cuantitativa mejor que una simple intuición.

El planteamiento se centró en los 15 productos con mayor demanda acumulada. Esta decisión responde a una lógica de negocio y también a una lógica metodológica. En proyectos reales, no siempre resulta eficiente modelizar todas las referencias a la vez, especialmente cuando muchas de ellas tienen un histórico pobre o una demanda demasiado residual. Focalizar el análisis en el núcleo principal del negocio permite obtener resultados más sólidos y comparables, y además evita que el aprendizaje quede contaminado por observaciones escasas o poco representativas.


El problema analítico se formuló, por tanto, como una tarea de predicción supervisada de una variable continua: la Cantidad_Total mensual por producto. Para resolverlo se compararon tres enfoques. En primer lugar, un baseline sencillo basado en repetir la cantidad del mes anterior. En segundo lugar, un modelo lineal regularizado Ridge, capaz de incorporar información temporal diversa con un grado razonable de estabilidad. Y, por último, un modelo no lineal XGBoost, escogido como versión final por su capacidad para capturar interacciones y relaciones más complejas dentro del histórico reciente.

Enlace de interés de GitHub y desarrollo de código: https://github.com/sroblespenamaria-byte/TFG_SR/tree/main

2. Diagrama de flujo.

Diagrama de flujo — Análisis del Dato

Proceso de preparación, modelización, comparación e interpretación final a partir del dataset_modelo_limpio.csv.



3. Objetivos e hipótesis de trabajo

La fase de análisis del dato partió de una hipótesis sencilla pero relevante: un modelo que combine memoria temporal reciente, señales de ventas y estacionalidad debería mejorar la predicción de demanda frente a una regla ingenua que solo replique el último valor observado. A partir de esta idea general, el trabajo se planteó varios objetivos concretos.

- Comparar el rendimiento de un baseline Naïve con modelos supervisados más estructurados.
- Valorar si un modelo lineal regularizado como Ridge es suficiente para capturar el patrón de demanda de los productos seleccionados.
- Comprobar si un modelo no lineal basado en Boosting mejora la capacidad predictiva respecto a Ridge.
- Interpretar qué variables temporales tienen mayor peso real dentro del modelo final.
- Analizar si el error es homogéneo entre productos o si existen referencias especialmente difíciles de predecir.
- Traducir los resultados técnicos a conclusiones útiles para compras, planificación y seguimiento comercial.

La hipótesis operativa de trabajo fue doble. Por un lado, se esperaba que las variables derivadas del comportamiento reciente (sobre todo medias móviles y lags) fuesen más relevantes que variables de calendario aisladas. Por otro, se anticipaba que XGBoost obtendría mejores resultados que Ridge al ser capaz de representar relaciones no lineales entre ventas, demanda y tendencia interna de cada producto.

4. Marco teórico de los modelos empleados

4.1. Predicción de demanda en entornos empresariales

La predicción de demanda constituye una de las aplicaciones más relevantes de la analítica en entornos empresariales, ya que permite anticipar decisiones relacionadas con compras, inventario, aprovisionamiento y planificación comercial. En este tipo de problemas, la variable objetivo no depende de un único factor, sino de la combinación de inercia histórica, comportamiento reciente, estacionalidad y posibles cambios de nivel en la serie. Por ello, la calidad del dato y la correcta construcción de variables temporales resultan tan importantes como el algoritmo finalmente seleccionado.

En este proyecto se trabaja con una frecuencia mensual, lo que sitúa el análisis en un punto intermedio entre la visión táctica y la visión operativa. Esta periodicidad reduce parte del ruido transaccional presente en escalas más finas y, al mismo tiempo, mantiene suficiente información para detectar tendencias, cambios de ritmo y concentraciones puntuales de demanda. En términos de negocio, esta escala es adecuada porque permite obtener previsiones útiles para la planificación sin perder completamente la lectura temporal del comportamiento comercial.

4.2. Baseline como referencia mínima

Todo proceso de modelización requiere una referencia mínima contra la que comparar los modelos más avanzados. En este trabajo, el baseline se definió como una regla ingenua consistente en utilizar la cantidad observada en el mes anterior como predicción para el mes siguiente. Aunque se trata de una aproximación sencilla, su valor metodológico es alto, ya que permite comprobar si la complejidad adicional de otros modelos está realmente justificada.

Este tipo de referencia resulta especialmente útil en problemas de forecasting porque representa la intuición más básica de continuidad temporal. Si un modelo más sofisticado no mejora claramente esta regla, entonces su aportación práctica sería limitada. Por el contrario, si consigue superarla de forma consistente, puede afirmarse que está capturando información adicional relevante dentro de la serie.

4.3. Ridge: modelo lineal regularizado

Ridge es una extensión de la regresión lineal clásica que incorpora regularización L2, es decir, una penalización sobre el cuadrado de los coeficientes del modelo. Su finalidad es controlar el tamaño de dichos coeficientes y evitar que el ajuste dependa en exceso de valores muy altos o inestables. De este modo, Ridge mantiene la lógica interpretable de una regresión lineal, pero añade un mecanismo de estabilización especialmente útil cuando existen variables explicativas correlacionadas entre sí.

En un contexto como el de este TFG, esta característica resulta especialmente adecuada porque varias de las variables construidas comparten información parcialmente solapada, como ocurre con los lags y las medias móviles de cantidad y ventas. La regularización ayuda a reducir la sensibilidad del modelo frente a ese solapamiento y favorece predicciones más robustas. Por ello, Ridge se plantea como una alternativa lineal sólida, interpretable y metodológicamente adecuada para comparar frente a modelos más flexibles.

4.4. Random Forest como etapa intermedia de exploración

Random Forest es un método de aprendizaje supervisado basado en conjuntos de árboles de decisión. Su lógica consiste en combinar múltiples árboles entrenados sobre subconjuntos de los datos y de las variables, con el objetivo de reducir la varianza y mejorar la estabilidad de la predicción respecto a un único árbol aislado. Dentro del proyecto, este modelo se utilizó como una etapa intermedia de exploración para comprobar si un enfoque no lineal basado en árboles era capaz de captar mejor la estructura del problema que un modelo puramente lineal.

La utilidad de incluir Random Forest en esta fase no radica en presentarlo como solución final, sino en mostrar una secuencia analítica razonable. Antes de adoptar XGBoost como modelo definitivo, era metodológicamente útil validar que las variables temporales construidas sí contenían señal predictiva real y observar si la relación entre predictores y demanda podía beneficiarse de una estructura no lineal. Esta fase intermedia ayudó, además, a obtener una primera lectura de la importancia relativa de las variables.

4.5. XGBoost como modelo final

XGBoost es una implementación optimizada del marco de gradient boosting aplicada, entre otros casos, a árboles de decisión. Su funcionamiento consiste en construir de forma secuencial varios modelos débiles, donde cada nuevo árbol intenta corregir los errores cometidos por los anteriores. Esta lógica permite capturar relaciones no lineales, interacciones y cambios de nivel con mayor flexibilidad que un modelo lineal tradicional. La documentación oficial lo define como una librería de gradient boosting altamente eficiente, flexible y portable, diseñada para ofrecer buen rendimiento en problemas tabulares.

En este TFG, XGBoost resulta especialmente adecuado porque la relación entre ventas recientes, demanda histórica y comportamiento por producto no tiene por qué ser estrictamente lineal. Además, el modelo permite extraer medidas de importancia de variables, lo que aporta un equilibrio interesante entre capacidad predictiva e interpretabilidad operativa. Esta combinación explica su elección como modelo final de referencia dentro del trabajo.

4.6. Métricas de evaluación

La comparación entre modelos se realizó mediante cuatro métricas complementarias. El MAE mide el error absoluto medio y facilita una lectura directa de cuántas unidades, en promedio, se desvía la predicción del valor real. El RMSE penaliza más los errores grandes y resulta útil cuando interesa castigar fallos severos.

El coeficiente R^2 resume cuánta variabilidad de la demanda queda explicada por el modelo. Por último, el WAPE expresa el error absoluto en términos relativos respecto al volumen total observado, lo que ayuda a comparar resultados con una lógica más cercana al negocio.

La elección de varias métricas no fue decorativa. Responde a la necesidad de evitar que la valoración del modelo dependa de un único criterio. Un modelo puede tener un buen ajuste global, pero comportarse mal en errores extremos, o al revés. Evaluarlo con varias medidas permite una selección más robusta y encaja con lo que exige la rúbrica de análisis del dato.

5. Diseño metodológico y construcción de variables

El punto de partida del análisis fue el dataset limpio de 7.624 registros y 14 variables. A partir de él se seleccionaron los quince productos con mayor demanda acumulada, reduciendo la muestra a 411 observaciones. Después se ordenaron cronológicamente los registros por producto y se creó una batería de variables derivadas para capturar memoria temporal y comportamiento reciente.

Entre las variables construidas destacan una tendencia interna por producto, lags de cantidad y de ventas a uno, dos, tres y seis meses, medias móviles y desviaciones móviles de tres y seis meses, y una codificación cíclica del mes mediante las funciones seno y coseno. Esta última decisión es interesante, porque evita tratar el calendario de manera lineal y permite reflejar mejor la naturaleza circular de la variable mes.

Para asegurar que todas estas variables derivadas tuviesen sentido, se eliminaron las observaciones sin histórico suficiente, dejando una muestra final de 366 registros. Posteriormente se aplicó una partición temporal realista: 293 registros para entrenamiento y 73 para test, utilizando como punto de corte abril de 2025. Este diseño reproduce una situación de predicción futura más coherente que una partición aleatoria, ya que impide que el modelo aprenda con información posterior al periodo que debe pronosticar. Este diseño metodológico buscó equilibrar realismo temporal, interpretabilidad y capacidad predictiva.

Tabla 1. Resumen del diseño muestral y temporal

Fase	Resultado
Dataset limpio de entrada	7.624 registros / 14 variables
Top 15 productos	411 registros
Dataset final tras crear histórico suficiente	366 registros / 31 columnas

Fase	Resultado
Train temporal	293 observaciones
Test temporal	73 observaciones
Mes de corte	2025-04

5.1. Variables predictoras utilizadas

Tabla 2. Estructura de las variables predictoras

Variable o bloque	Sentido analítico
N_producto	Identificación del producto
Año y Mes_Num	Contexto temporal básico
month_sin / month_cos	Estacionalidad cíclica del mes
tendencia_producto	Posición temporal acumulada de cada producto
lag_qty_1, lag_qty_2, lag_qty_3, lag_qty_6	Memoria reciente de la demanda
lag_sales_1, lag_sales_2, lag_sales_3, lag_sales_6	Memoria reciente de las ventas
roll_mean_qty_3 y roll_mean_qty_6	Nivel medio reciente de la demanda
roll_std_qty_3 y roll_std_qty_6	Variabilidad reciente de la demanda
roll_mean_sales_3 y roll_mean_sales_6	Nivel medio reciente de ventas

6. Resultados del contraste entre modelos

Los resultados confirman que los modelos supervisados superan con claridad al baseline. El modelo XGBoost obtuvo el mejor comportamiento global, con un MAE de 149,09, un RMSE de 269,91, un R^2 de 0,6836 y un WAPE de 0,5299. Ridge quedó muy cerca, con un MAE de 149,78, un RMSE de 287,99, un R^2 de 0,6398 y un WAPE de 0,5323. El baseline, por el contrario, registró un RMSE de 429,34 y un R^2 de apenas 0,1995, lo que evidencia su incapacidad para capturar adecuadamente la dinámica observada.

La conclusión principal es que la ingeniería de variables temporales sí aporta valor real. Tanto Ridge como XGBoost aprovechan la información histórica para mejorar la predicción, pero XGBoost consigue un ajuste más fino, especialmente al reducir el peso de errores grandes y al capturar relaciones no lineales entre la demanda y sus señales recientes. En términos relativos, frente al baseline, XGBoost reduce el RMSE aproximadamente un 37 % y mejora de manera muy notable la capacidad explicativa del modelo.

Tabla 3. Comparación final de modelos

Modelo	MAE	RMSE	R ²	WAPE
XGBoost	149,09	269,91	0,6836	0,5299
Ridge	149,78	287,99	0,6398	0,5323
Baseline_lag1	176,45	429,34	0,1995	0,6271

6.1. Lectura visual de la predicción mensual

La representación mensual agregada ayuda a interpretar mejor el significado de las métricas. En la fase preliminar con Random Forest ya se observaba que los modelos avanzados eran capaces de acercarse mejor a la serie real que el baseline. Sin embargo, la versión mejorada con XGBoost muestra una trayectoria más sólida, especialmente en los meses centrales del periodo de prueba. Aun así, persisten dificultades para reproducir por completo algunos picos de demanda, lo que es habitual en series con concentración por producto y por cliente.

El gráfico comparativo sugiere además que Ridge tiende a suavizar la serie, mientras que XGBoost se adapta mejor a cambios de nivel. Esta diferencia es coherente con la naturaleza de ambos modelos: uno lineal y regularizado; el otro, no lineal y más flexible.




Figura 1. Demanda real vs predicha por mes en la fase preliminar con Random Forest.




Figura 2. Demanda real vs predicha por mes en la versión final con XGBoost.

6.2. Dispersión real vs. predicho

Los diagramas de dispersión completan la lectura anterior. Cuanto más cerca se sitúan los puntos de la diagonal, mejor reproduce el modelo el valor real. En Ridge se aprecia un comportamiento relativamente estable, pero con tendencia a infraestimar algunos valores altos. Random Forest, por su parte, ofrece una primera mejora respecto a una lógica lineal simple, aunque todavía presenta dispersión notable en registros

de mayor volumen. XGBoost consigue una nube más coherente y más alineada con la diagonal, lo que refuerza su elección como modelo final del trabajo.

Es importante destacar que en problemas reales de demanda no se espera una coincidencia perfecta punto a punto. Lo relevante es mejorar de forma consistente la aproximación respecto a una referencia ingenua y reducir el error agregado de forma operativamente útil. En este sentido, la dispersión observada sigue siendo compatible con un uso práctico del modelo como herramienta de apoyo a la planificación.




Figura 3. Dispersión real vs predicho para Random Forest.




Figura 4. Dispersión real vs predicho para Ridge.




Figura 5. Dispersión real vs predicho para XGBoost.

6.3. Importancia de variables

Las gráficas de importancia de variables ayudan a responder una pregunta clave del proyecto: ¿de dónde está extrayendo información el modelo para predecir? Tanto en Random Forest como en XGBoost se observa un patrón común, que es: las variables relacionadas con la memoria reciente de la demanda y de las ventas son las más determinantes. Este resultado es muy coherente con la lógica del negocio, donde la demanda futura depende en buena medida de la inercia de los últimos meses.

En el caso final de XGBoost, las variables más influyentes fueron `roll_mean_qty_3`, `roll_mean_sales_3` y `roll_mean_qty_6`, seguidas por la pertenencia a ciertos productos concretos como 3667 y 3668, además de algunos lags recientes de ventas y cantidad. La estacionalidad y el año aparecen, pero con un peso menor. Esto significa que el modelo se apoya sobre todo en la trayectoria reciente del producto y no tanto en una pauta de calendario rígida.




Figura 6. Top 15 variables más importantes en Random Forest.




Figura 7. Top 15 variables más importantes en XGBoost.

Tabla 4. Principales variables del modelo XGBoost

Variable	Importancia
roll_mean_qty_3	0,2609
roll_mean_sales_3	0,1703
roll_mean_qty_6	0,1252
N_producto_3667	0,0964
lag_sales_1	0,0354
lag_qty_1	0,0289
roll_std_qty_3	0,0265
N_producto_3668	0,0214
lag_qty_3	0,0211
month_sin	0,0195

7. Interpretación por producto y discusión de resultados

Una ventaja adicional de la solución final es que permite analizar el error por producto. Esta desagregación muestra que los mayores errores absolutos se concentran en las referencias 3667 y 3668, precisamente las que acumulan una demanda real más elevada dentro del periodo de test. Este resultado no debe interpretarse de forma negativa sin más. En productos muy relevantes y más volátiles es razonable que el error absoluto también crezca.

En cambio, productos con menor volumen como 6750_, 5614_ o 3648 presentan errores considerablemente más bajos. La lectura práctica es que el modelo se adapta mejor cuando el patrón de demanda es más estable y empeora cuando la referencia está sometida a cambios intensos de ritmo. Este hallazgo abre una línea de mejora clara: en futuras iteraciones podría ser útil y muy interesante segmentar productos por nivel de variabilidad o incluso entrenar modelos diferenciados para las referencias más críticas.

También merece la pena subrayar que algunos productos con demanda relativamente pequeña, como CO14000, presentan un RMSE alto en términos relativos. Esto sugiere que los productos muy esporádicos o de comportamiento menos regular siguen siendo difíciles de anticipar incluso con un modelo flexible

como XGBoost. En otras palabras, el modelo final es útil y mejora claramente la referencia, pero no elimina por completo la incertidumbre inherente al negocio.

Tabla 5. Métricas por producto del modelo XGBoost

Producto	MAE	RMSE	Demanda real en test
3667	560,44	631,16	6.944
3668	546,99	621,90	6.017
CO14000	178,56	201,24	44
3647_	111,86	159,74	1.252
3669	125,94	151,68	875
1373_	91,74	94,32	2.179
FA7501	79,17	88,04	808
6749_	53,40	68,99	509
3836	52,12	68,80	375
3648	31,54	35,67	480
1393-NARANJA-PEQ	31,71	35,30	504
5614_	27,90	33,03	413
6750_	13,59	15,54	140

8. Implicaciones de negocio y recomendaciones

Los resultados obtenidos permiten extraer recomendaciones concretas para la empresa. En primer lugar, el modelo puede utilizarse como herramienta de apoyo para planificar compras y aprovisionamiento de las referencias con más peso. No sustituye el criterio comercial ni el conocimiento del cliente, pero sí aporta una señal cuantitativa mejor que la repetición mecánica del último dato observado.

En segundo lugar, la importancia de las variables confirma que la demanda reciente y el nivel medio de ventas de los últimos meses son los mejores predictores de corto plazo. Esto refuerza la necesidad de mantener actualizado un cuadro de mando operativo con seguimiento mensual por producto y con especial atención a medias móviles, variabilidad y cambios bruscos de nivel.

En tercer lugar, el hecho de que unos pocos productos concentren gran parte del error total sugiere una estrategia de priorización. No todos los productos requieren el mismo esfuerzo analítico. Las referencias 3667 y 3668, por ejemplo, deberían tratarse como productos estratégicos dentro del seguimiento, ya sea con alertas específicas, revisión comercial adicional o incluso modelos dedicados.

Por último, la mejora clara frente al baseline demuestra que la empresa puede avanzar hacia una toma de decisiones más apoyada en datos sin necesidad de recurrir de entrada a modelos excesivamente complejos o de difícil mantenimiento. Un pipeline mensual bien definido con actualización periódica del modelo sería ya una mejora real sobre la situación inicial.

8.1. Discusión crítica de los resultados y del comportamiento del error

La comparación con Ridge es igualmente útil. Ridge se comporta de manera muy competitiva y demuestra que una estructura lineal bien regularizada ya capta una parte importante del patrón. Sin embargo, la ventaja final de XGBoost sugiere que la demanda de estos productos no sigue una relación puramente lineal con sus predictores. Hay interacciones, umbrales y cambios de régimen que el modelo de boosting es capaz de capturar mejor. Esta lectura es importante porque evita caer en una conclusión simplista de “cuanto más complejo, mejor”. En realidad, primero se comprueba que un modelo lineal funciona razonablemente bien y después se justifica por qué merece la pena ir un paso más allá.

El contraste con el baseline permite cuantificar con claridad el valor añadido del enfoque analítico. El modelo final XGBoost reduce el RMSE desde 429,34 hasta 269,91, mejora el MAE frente a 176,45 y eleva el R^2 desde 0,1995 hasta 0,6836. Estos cambios no son marginales. Suponen pasar de una predicción bastante pobre, limitada a copiar la inercia más inmediata, a una predicción capaz de explicar una proporción mucho más alta de la variabilidad de la demanda. Esta mejora es precisamente la que justifica el esfuerzo previo de ingeniería del dato y construcción de variables.

8.2. Mejora relativa frente al baseline y lectura comparativa por modelos

También es relevante el hecho de que las medias móviles aparezcan como variables dominantes. Esto quiere decir que, para la gestión, no basta con mirar el último dato aislado. El comportamiento reciente agregado contiene más información que una observación puntual. En la práctica, esta conclusión justifica que la empresa complemente el seguimiento del mes corriente con indicadores de tendencia a tres y seis meses, tanto en cantidades como en ventas. El modelo no solo predice; también señala qué métricas conviene vigilar dentro del cuadro de mando.

Desde una óptica funcional, el resultado del modelo final es especialmente interesante para compras y planificación. Que XGBoost mejore de forma clara al baseline significa que la empresa dispone ya de una

señal más rica que la simple repetición del último mes. Esto permite anticipar mejor si una referencia viene sosteniendo un crecimiento, si se encuentra en una fase de estabilización o si ha entrado en una dinámica de corrección. En referencias con un peso fuerte sobre la facturación o sobre el servicio al cliente, disponer de esa señal con antelación puede traducirse en decisiones de aprovisionamiento menos reactivas.

8.3. Lectura del resultado desde compras y planificación

Además, el modelo puede integrarse en un cuadro de mando donde convivan predicción, histórico reciente, ventas y alertas de desvío. En caso de incorporar indicadores económicos complementarios, su interpretación debería realizarse con cautela y siempre en función de la disponibilidad real de la información de coste. Este tipo de integración reforzaría mucho la utilidad práctica del trabajo, porque transformaría una memoria académica en un flujo operativo replicable. El dato no quedaría encerrado en una tabla de resultados, sino que pasaría a formar parte de una lógica de seguimiento continua. En un negocio con referencias de alto peso relativo, este uso recurrente es probablemente más valioso que la búsqueda de un modelo teóricamente perfecto pero difícil de mantener.

Si se traslada el resultado del TFG a un entorno de uso real, la implantación más razonable sería mensual. La empresa podría actualizar el dataset consolidado al cierre de cada mes, recalcular automáticamente las variables temporales y generar una nueva predicción para el periodo siguiente sobre los productos estratégicos. Esta rutina no exige una infraestructura tecnológica desproporcionada. De hecho, uno de los méritos del proyecto es que demuestra que puede obtenerse valor analítico combinando herramientas relativamente accesibles: Power Query, Power BI y Python. En términos de gestión, disponer de una previsión mensual no significa automatizar la decisión final, sino mejorar la conversación entre compras, planificación y comercial con una referencia cuantitativa objetiva.

8.4. Escenario práctico de implantación del modelo

El modelo desarrollado en este trabajo puede aplicarse de forma práctica como herramienta de apoyo a la toma de decisiones en las áreas de compras, planificación y seguimiento comercial. Su utilidad principal no consiste en sustituir el criterio de la empresa, sino en aportar una referencia cuantitativa adicional que permita anticipar mejor la demanda de los productos más relevantes del negocio.

El escenario de implantación más razonable sería una actualización mensual. Una vez cerrados los datos del periodo, la empresa podría consolidar la información de ventas y productos, actualizar el dataset analítico y ejecutar de nuevo el modelo para obtener una previsión del mes siguiente. De este modo, se generaría un flujo de trabajo repetible y útil para el seguimiento del negocio.

Desde el punto de vista operativo, esta implantación permitiría mejorar la planificación de compras, reducir decisiones puramente reactivas y detectar con mayor antelación posibles cambios en la demanda. También tendría valor como apoyo al análisis comercial, ya que una desviación importante entre previsión e histórico podría servir como señal de alerta para revisar el comportamiento de determinados productos o clientes.

Además, una de las ventajas del trabajo es que su implantación no requeriría una infraestructura especialmente compleja, ya que puede apoyarse en herramientas accesibles como Excel, Power BI y Python. A medio plazo, incluso podría integrarse dentro de un cuadro de mando para visualizar conjuntamente histórico, predicción y principales indicadores operativos.

En definitiva, el modelo puede entenderse como una herramienta realista de apoyo a la gestión, capaz de mejorar la anticipación y reforzar una toma de decisiones más basada en datos.

9. Limitaciones y líneas futuras

La primera limitación del trabajo está en el tamaño de la muestra para algunos productos. Aunque el dataset global limpio es amplio, al restringir el análisis a los productos principales y exigir histórico suficiente, el número final de observaciones para entrenar sigue siendo moderado. Esto no invalida los resultados, pero sí aconseja interpretar con prudencia cualquier conclusión demasiado fina por referencia.

La segunda limitación tiene que ver con el nivel de agregación. El análisis trabaja con datos mensuales, lo cual es adecuado para el objetivo del proyecto, pero no captura posibles patrones semanales o intra-mensuales. Si la empresa quisiera avanzar hacia una planificación más detallada, sería recomendable estudiar granularidades más finas siempre que el histórico lo permita.

Una limitación adicional está relacionada con la interpretación de variables económicas complementarias, especialmente el margen. Aunque esta métrica puede aportar contexto financiero al análisis, su lectura queda condicionada por la disponibilidad del coste analítico en el dataset de partida. Por ello, dentro de esta memoria el foco principal se mantiene en la predicción de demanda, mientras que cualquier lectura del margen debe entenderse como una aproximación complementaria y no como una representación global de la rentabilidad del negocio.

Una tercera limitación es que el modelo se apoya fundamentalmente en histórico interno. Quedan fuera variables externas que podrían enriquecer la predicción, como campañas comerciales, disponibilidad de stock, información de vendedores, plazos logísticos o eventos específicos del mercado sanitario. Integrar este tipo de señales podría mejorar especialmente la predicción de picos o meses excepcionales.

Como líneas futuras, destacan tres posibilidades: ampliar el horizonte temporal del dataset, segmentar productos por comportamiento para asignar modelos distintos y explorar variantes adicionales como LightGBM, CatBoost o modelos específicos por familia de producto. También sería valioso convertir la salida del modelo en un flujo integrado dentro de Power BI para que las predicciones se visualicen junto con los indicadores operativos mensuales.

10. Conclusiones

La fase de análisis del dato demuestra que la predicción de demanda planteada en el TFG es viable y aporta valor real. El contraste entre modelos confirma que una estrategia basada en variables temporales derivadas supera claramente a un baseline ingenuo y que, dentro de las alternativas probadas, XGBoost ofrece el mejor comportamiento global.

Más allá de la mejora métrica, el análisis también deja una conclusión conceptual importante: la demanda futura depende sobre todo de su memoria reciente. Las medias móviles y los lags son las señales con mayor capacidad explicativa, mientras que la estacionalidad y el calendario aportan un papel secundario. Esta lectura es coherente con el negocio estudiado y refuerza la utilidad de un seguimiento mensual bien estructurado.

En este contexto, las conclusiones más sólidas de la fase analítica se apoyan especialmente en las variables de demanda y ventas, ya que ambas permiten una lectura global y consistente del comportamiento comercial. Por su parte, los indicadores económicos como el margen pueden aportar una referencia útil, pero su interpretación debe hacerse con mayor prudencia cuando la disponibilidad del coste analítico no es homogénea en todos los registros.

En conjunto, la parte analítica cierra el círculo iniciado en la ingeniería del dato. Gracias a una base limpia y a una metodología de evaluación rigurosa, el proyecto no se limita a describir el pasado, sino que propone una herramienta concreta para anticipar el comportamiento de los productos más relevantes del negocio.

Ahora bien, también hay límites evidentes. La presencia de errores elevados en productos muy demandados indica que la predicción de picos sigue siendo un reto. En términos prácticos, esto quiere decir que el modelo ayuda a reducir incertidumbre, pero no elimina la necesidad de supervisión humana en los momentos críticos. A su vez, el comportamiento desigual por producto aconseja no leer el resultado como si todas las referencias respondieran del mismo modo. El valor del trabajo está precisamente en haber mostrado esa heterogeneidad y en haber identificado qué productos merecen un control más cercano.

Una lectura crítica de los resultados obliga a reconocer tanto los aciertos como los límites del modelo final. El principal acierto está en la mejora consistente frente a la referencia ingenua y en la coherencia entre métricas, visualizaciones e importancia de variables. No se trata de un modelo que funcione bien en un solo indicador y fracase en el resto, sino de un comportamiento razonablemente sólido en varias dimensiones a la vez. Además, la interpretación económica del resultado es clara: el modelo aprende sobre todo de la trayectoria reciente de cada producto.

11. Bibliografía

- Microsoft. (2026). *Documentación de Power BI*. Microsoft Learn.
- OpenAI. (2026). *ChatGPT*. OpenAI Help Center.
- Pandas development team. (2026). *pandas documentation*. PyData.
- Python Software Foundation. (2026). *Documentación de Python*. Python.org.
- scikit-learn developers. (2026). *User Guide: scikit-learn*. scikit-learn.
- The Matplotlib development team. (2026). *Matplotlib documentation*. Matplotlib.
- XGBoost contributors. (2026). *XGBoost documentation*. [xgboost.readthedocs.io](https://xgboost.ai).
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
- scikit-learn developers. (2026). *Ridge regression*. scikit-learn documentation.
- XGBoost contributors. (2026). *XGBoost documentation*.
- XGBoost contributors. (2026). *Introduction to Boosted Trees*.

Declaración sobre el uso de herramientas de inteligencia artificial

Durante la elaboración de esta memoria se ha utilizado **ChatGPT, de OpenAI**, como herramienta de apoyo puntual para la mejora de la redacción, la organización de ideas, la reformulación de algunos fragmentos y la revisión formal del documento. Su uso ha sido complementario y en ningún caso ha sustituido el análisis propio, la selección metodológica, la interpretación de resultados ni la elaboración de las conclusiones, que han sido realizadas por el autor.

Anexo A. Resumen final de resultados clave

- XGBoost fue el mejor modelo del trabajo con RMSE 269,91 y R^2 0,6836.
- Ridge ofreció un comportamiento competitivo, pero algo inferior en ajuste global.
- El baseline fue claramente superado, lo que valida la utilidad de la modelización.
- Las medias móviles y los lags dominaron la importancia de variables.
- Los productos 3667 y 3668 concentran la mayor parte del error absoluto y requieren seguimiento prioritario.

Anexo B. Resultados complementarios de la fase preliminar con Random Forest

Antes de fijar la solución definitiva con XGBoost, el proyecto comparó un baseline, Ridge y Random Forest sobre una primera estructura de variables temporales. Aunque Random Forest no fue el modelo ganador, sí resultó útil como etapa intermedia para comprobar si un enfoque no lineal basado en árboles aportaba señal predictiva adicional frente a un modelo lineal regularizado.

Modelo	MAE	RMSE	R ²	WAPE
Ridge	153,64	292,63	0,6281	0,5460
RandomForest	164,63	323,44	0,5457	0,5851
Baseline_lag1	176,45	429,34	0,1995	0,6271

Tabla B1. Comparación de modelos en la fase preliminar con Random Forest.

Los resultados muestran que Ridge ya superaba claramente al baseline en esta fase preliminar, mientras que Random Forest mejoraba la lectura no lineal de la demanda, pero sin alcanzar todavía el rendimiento del modelo final. Esta comparación justifica metodológicamente el paso posterior hacia una arquitectura boosting más flexible.

Variable	Importancia
roll_mean_3	0,6446
lag_sales_1	0,0884
lag_qty_1	0,0459
roll_std_3	0,0399
lag_qty_3	0,0383
lag_qty_2	0,0337
tendencia_producto	0,0253
lag_sales_3	0,0223
Mes_Num	0,0221
lag_sales_2	0,0121
N_producto_3667	0,0111
N_producto_3668	0,0053

Año	0,0053
N_producto_1373_	0,0037
N_producto_3669	0,0005

Tabla B2. Top 15 variables más importantes en Random Forest.

La importancia de variables en Random Forest ya anticipaba una conclusión que luego se consolidó con XGBoost: las medias móviles y los retardos recientes eran el núcleo explicativo del problema.

Anexo C. Detalle ampliado del modelo final XGBoost

El modelo XGBoost se adoptó como solución final por ofrecer el mejor equilibrio entre error absoluto, error cuadrático y capacidad explicativa. En este anexo se incluyen dos tablas de apoyo: la importancia detallada de variables y las métricas desagregadas por producto en la muestra de test.

Variable	Importancia
roll_mean_qty_3	0,2609
roll_mean_sales_3	0,1703
roll_mean_qty_6	0,1252
N_producto_3667	0,0964
lag_sales_1	0,0354
lag_qty_1	0,0289
roll_std_qty_3	0,0265
N_producto_3668	0,0214
lag_qty_3	0,0211
month_sin	0,0195
Año	0,0194
N_producto_1373_	0,0190
lag_qty_2	0,0186
lag_qty_6	0,0176
roll_mean_sales_6	0,0174

Tabla C1. Importancia detallada de variables en XGBoost.

La jerarquía de variables confirma que la información más útil para la predicción se concentra en el comportamiento reciente del producto: medias móviles de cantidad y ventas, lags y, en menor medida, componentes estacionales y algunas referencias concretas con mayor peso en la serie.

Producto	MAE	RMSE	Demanda real en test
3667	560,44	631,16	6.944
3668	546,99	621,90	6.017
CO14000	178,56	201,24	44

3647_	111,86	159,74	1.252
3669	125,94	151,68	875
1373_	91,74	94,32	2.179
FA7501	79,17	88,04	808
6749_	53,40	68,99	509
3836	52,12	68,80	375
3648	31,54	35,67	480
1393-NARANJA-PEQ	31,71	35,30	504
5614_	27,90	33,03	413
6750_	13,59	15,54	140

Tabla C2. Métricas por producto del modelo XGBoost.

La lectura por producto permite identificar dónde se concentra el error. Las referencias 3667 y 3668 son las que más contribuyen al error total, no solo por su complejidad, sino también por su mayor volumen de demanda. En cambio, otras referencias menores presentan errores mucho más contenidos y un comportamiento más estable.