

Universidad Francisco de Vitoria

Grado en Business Analytics

Memoria de Ingeniería del Dato

Proyecto Pulso: análisis y predicción de la demanda en una empresa de electromedicina

Proyecto de Business Analytics orientado al análisis y predicción de demanda

Trabajo Fin de Grado

Alumno: Santiago Robles Peñamaría

Tutor: Rufino Prieto Alonso

Curso académico 2025-2026

ÍNDICE ORIENTATIVO

ÍNDICE ORIENTATIVO	2
1. Introducción y alcance de la fase.....	4
2. Diagrama de flujo.....	5
3. Objetivos de la ingeniería del dato	6
4. Origen de los datos y arquitectura de trabajo	6
Tabla 1. Arquitectura resumida del flujo de trabajo	7
5. Proceso de limpieza, transformación e integración.....	7
5.1. Normalización estructural en Python	7
5.2. Tratamiento de nulos y filtros de calidad	8
5.3. Dataset resultante tras la limpieza	8
Tabla 2. Magnitudes clave del dataset a lo largo del proceso	9
6. Decisiones metodológicas previas en Power Query y Power BI.....	9
7. Análisis exploratorio del dataset resultante	10
7.1. Evolución mensual de la demanda agregada.....	10
7.2. Evolución mensual de las ventas totales	11
7.3. Evolución mensual del margen sobre registros con coste analítico informado.....	12
7.4. Segmentación por tipo de cliente	13
7.5. Concentración por clientes	14
7.6. Concentración geográfica por provincias	15
7.7. Síntesis del análisis exploratorio	16
8. Preparación del conjunto analítico para modelización	17
Tabla 3. Productos incluidos en la fase predictiva	17
9. Discusión metodológica en relación con la rúbrica.....	18
9.1. Relación entre la ingeniería del dato y el valor de negocio.....	18
9.2. Controles de validación y coherencia del dato	19

9.3. Justificación de la agregación mensual y de la unidad de análisis	19
9.4. Reproducibilidad, trazabilidad y valor metodológico de la fase	20
10. Limitaciones de la fase	21
11. Conclusiones	21
12. Bibliografía	23
9.4. Reproducibilidad, trazabilidad y valor metodológico de la fase	24
Anexo A. Variables del dataset limpio	24
Anexo B. Gráfico exploratorio de referencia validado en Power BI	25
Anexo C. Tablas de apoyo al análisis exploratorio	26

1. Introducción y alcance de la fase

La parte de ingeniería del dato constituye el soporte técnico sobre el que depende el resto del Trabajo Fin de Grado. En este proyecto de Business Analytics no basta con aplicar modelos o construir visualizaciones finales. Antes es necesario asegurar que la información con la que se parte sea consistente, trazable y útil desde un punto de vista analítico. En este caso, el proyecto se centra en una empresa del ámbito de la electromedicina, con información histórica de compras, ventas, costes, clientes y productos procedente de exportaciones de Navision a Excel y de tablas derivadas construidas en Power Query y Power BI.


El objetivo de esta memoria no es solo describir de forma común una secuencia ETL teórica, sino reconstruir con detalle el trabajo real que he desarrollado a lo largo del proyecto. Por ello, se recogen tanto las decisiones tempranas de limpieza y estructuración realizadas en la fase inicial del TFG como el tratamiento posterior efectuado con scripts de Python. Esta doble capa la considero de vital importancia, ya que el dataset final empleado en modelización no surgió de un único paso automático, sino de una cadena de decisiones sucesivas encaminadas a reducir ruido, eliminar inconsistencias y construir un repositorio mensual comparable por producto.

La fase de ingeniería del dato se ha planteado con una lógica claramente aplicada. No se trataba de depurar la información por motivos puramente formales, sino de dejar lista una base analítica capaz de responder preguntas de negocio como lo son: qué productos concentran la mayor demanda, cómo evoluciona la facturación mes a mes, qué segmentos de cliente sostienen la mayor parte de ventas y qué estructura temporal resulta más adecuada para predecir la demanda futura. Desde esa perspectiva, la limpieza, la transformación y el análisis exploratorio pasan a ser decisiones estratégicas del proyecto y no simples tareas previas.

Enlace de interés de GitHub y desarrollo de código: https://github.com/sroblespenamaria-byte/TFG_SR/tree/main

2. Diagrama de flujo

La siguiente figura resume el flujo completo seguido desde la extracción de datos hasta la construcción del dataset analítico final.



3. Objetivos de la ingeniería del dato

La fase de ingeniería del dato persiguió un objetivo principal: construir un dataset analítico robusto, interpretable y orientado a predicción a partir de ficheros operacionales que eran heterogéneos. Este objetivo general se concretó en varios objetivos específicos que guiaron toda la preparación de los datos.

- Unificar la estructura de campos y nombres de variables procedentes de distintas exportaciones y etapas de tratamiento.
- Transformar columnas con formatos inconsistentes para garantizar tipos correctos en fechas, importes, cantidades y márgenes.
- Detectar y tratar valores nulos, además de registros no comparables y observaciones con anomalías comerciales que han podido distorsionar el análisis posterior.
- Justificar la eliminación de variables sin capacidad explicativa, ya fuera por ausencia total de información, por valor constante o por falta de utilidad analítica.
- Construir un dataset mensual por producto que sirviera como base para el análisis exploratorio y la modelización de demanda.
- Generar una primera lectura descriptiva del negocio mediante series temporales y segmentaciones por cliente, tipo de cliente y provincia.
- Dejar preparada la transición hacia la fase de análisis del dato, especialmente en lo relativo a selección de productos, estructura temporal y variables derivadas.

4. Origen de los datos y arquitectura de trabajo

Los datos empleados en el proyecto proceden del sistema de gestión de la empresa, exportados inicialmente a Excel desde Navision y posteriormente tratados en herramientas de autoservicio (Excel, Power BI y Power Query) y en Python. La estructura original incluía información de facturación y compraventa, movimientos e inventario, clientes, productos y hojas auxiliares de composición de aparatos. Desde el punto de vista

metodológico, esto supuso trabajar con datos que presentaban distintos niveles de detalle y con variables que, en su origen, no habían sido diseñadas específicamente para fines analíticos.

La arquitectura de trabajo seguida puede describirse como un flujo híbrido entre ELT y ETL. En una primera fase, gran parte de la integración y depuración se llevó a cabo en Power Query y Power BI, aprovechando su buena capacidad para unir tablas, eliminar columnas que no hacían falta y construir dimensiones limpias. En una segunda fase, una vez exportado el dataset mensual ya consolidado, Python se utilizó para una limpieza adicional, para la validación estructural y para la preparación del conjunto final de modelización. Esta forma de trabajar responde bien al contexto real del proyecto. Power BI facilita el modelado orientado a negocio y Python aporta un control analítico más fino y con más reproducibilidad.

Tabla 1. Arquitectura resumida del flujo de trabajo

Capa del proceso	Función en el proyecto
Exportaciones operacionales	Excels procedentes de Navision con datos de ventas, costes, movimientos y clientes.
Power Query / Power BI	Limpieza inicial, unificación de tablas, creación de dimensiones y construcción del dataset mensual consolidado.
Python	Validación final, limpieza estructural, análisis exploratorio y preparación para predicción.
Dataset final de modelización	Archivo mensual por producto con 7.624 registros iniciales y 14 variables tras la fase de limpieza.

5. Proceso de limpieza, transformación e integración

5.1. Normalización estructural en Python

El primer script de la fase operativa en Python tuvo como finalidad cargar el archivo mensual ya consolidado y revisar su consistencia. El dataset de entrada contenía 7.624 registros y 14 variables, con una mezcla de tipos numéricos, cadenas y fechas. Esta comprobación inicial nos permitió confirmar que la información necesaria para la predicción estaba ya agrupada a nivel de mes y producto, lo cual simplificaba mucho el modelado posterior y evitaba volver a trabajar desde el detalle de línea de factura, esto es debido a que las fases previas se hicieron correctamente y a conciencia.

Uno de los primeros pasos consistió en normalizar los nombres de las columnas. Se eliminaron prefijos innecesarios como “Suma de”, se sustituyeron espacios por guiones bajos y se limpiaron caracteres que en un flujo analítico suelen dar problemas, como lo son los puntos, símbolos de porcentaje o algo que da muchos problemas, el ordinal “º”. Esta decisión, aunque técnica, tiene una importancia práctica clara, que es la de evitar errores al programar, mejora la legibilidad del código y hace más estable el pipeline cuando se reutiliza en distintos entornos.

A continuación, se realizó una conversión explícita de tipos. La variable “Fecha_Mes” se transformó a “tipo fecha”, “Año_mes” y “N_producto” se trataron como texto, y las variables cuantitativas principales — cantidad, ventas, costes, márgenes y flags— se convirtieron a formato numérico. Este paso permitió evitar la mezcla de tipos y facilitó tanto los agregados exploratorios como el cálculo posterior de variables temporales.

5.2. Tratamiento de nulos y filtros de calidad

Tras la conversión de tipos se revisó la presencia de nulos por columna. En esta fase se optó por un tratamiento prudente y justificado: el porcentaje de margen se rellenó con cero cuando estaba ausente y la cantidad total también se completó con cero en aquellos casos en los que el vacío no representaba una observación útil para el análisis. La lógica detrás de esta decisión es que, al trabajar con una tabla ya agregada mensualmente, no interesaba introducir interpolaciones arbitrarias que alterasen el significado económico del registro.

Más relevante todavía fue la aplicación de filtros de calidad sobre el dataset. Se conservaron únicamente los registros clasificados como “Normal” dentro de la variable “Tipo_Registro” y se eliminaron las observaciones marcadas con “Flag_Anomalia_Comercial” que eran igual a 1. Esta depuración tiene un efecto metodológico importante: evita que la fase predictiva aprenda patrones derivados de operaciones atípicas, devoluciones o movimientos no comparables con la actividad ordinaria del negocio.

Una vez aplicados estos filtros, el dataset se ordenó por producto y fecha. Este orden cronológico no solo mejora la trazabilidad del trabajo, sino que resulta imprescindible para las transformaciones de series temporales realizadas después, como retardos, medias móviles o cortes de entrenamiento y validación.

5.3. Dataset resultante tras la limpieza

El resultado de esta fase fue un archivo limpio, coherente y listo para uso analítico, que fue guardado como `dataset_modelo_limpio.csv`. Su estructura final de trabajo conservó 14 variables esenciales: Año, Año_mes, Cantidad_Total, Coste_Total_Analitico, Fecha_Mes, Flag_Anomalia_Comercial, Flag_Margen_Negativo, Flag_Ventas_Cero, Margen_Bruto, Margen_Porcentaje, Mes_Num, N_producto, Tipo_Registro y

Ventas_Totales. La principal ventaja de esta estructura es que sintetiza información comercial y económica relevante sin cargar el modelo con columnas redundantes o sin valor predictivo.

Desde el punto de vista de la rúbrica de ingeniería del dato, esta fase acredita no solo una clara limpieza básica, sino una explicación completa del proceso de transformación, filtrado y justificación de variables. No se trata únicamente de haber obtenido un archivo usable, sino de haber documentado por qué cada decisión tenía sentido en términos analíticos y de negocio. Una vez construido el dataset analítico final, se realizó una revisión adicional de coherencia sobre las variables económicas derivadas.

Esta validación permitió además revisar con mayor cautela la interpretación de las variables económicas derivadas, especialmente el margen, cuya representación final se ajustó a la disponibilidad real del coste analítico.

Tabla 2. Magnitudes clave del dataset a lo largo del proceso

Indicador	Valor
Registros iniciales del dataset mensual limpio	7.624
Número de variables en el dataset	14
Productos seleccionados para modelado posterior	15
Registros tras filtrar top 15 productos	411
Registros finales tras generar histórico temporal suficiente	366

6. Decisiones metodológicas previas en Power Query y Power BI

Antes de llegar al script final de Python, el proyecto ya había incorporado una fase importante de depuración en Power Query y Power BI. Esta parte debe documentarse porque explica por qué el dataset consolidado llega a Python con una estructura relativamente compacta. Varias columnas de la tabla Facturación_CompraVenta fueron eliminadas por no aportar capacidad explicativa o por carecer de información útil para el análisis así queda todo mucho más limpio.

En concreto, se eliminó la columna “Código variante” por no contener datos. También se descartaron “Nº lín. orden producc.” y “Nº lín. comp. orden prod.”, ya que presentaban un único valor constante igual a cero en todos los registros. Lo mismo ocurrió con varias variables de costes y ventas esperadas, entre ellas

“Importe coste (Real) (DA)”, “Importe coste (no-invent.)(DA)”, “Importe coste (No-invent.)”, “Importe coste (Esperado) (DA)”, “Importe coste (Esperado)”, “Cantidad reservada” e “Importe ventas (Esperado)”, todas ellas irrelevantes para el análisis al no aportar variabilidad o no ser informativas.

Del mismo modo, en la construcción de la dimensión de productos se eliminaron registros con N° producto nulo o sin identificador válido, así como filas con contenido no interpretable. La razón fue garantizar que cada producto quedase representado de forma unívoca dentro del modelo y evitar duplicidades semánticas. Esta decisión es muy importante, porque una dimensión de producto sucia habría trasladado ruido tanto al análisis exploratorio como a la fase predictiva.

- Eliminación de columnas vacías o sin datos efectivos.
- Eliminación de columnas constantes sin capacidad explicativa.
- Depuración de identificadores de producto no válidos.
- Priorización de variables con sentido económico para ventas, margen y demanda.
- Construcción de un modelo analítico más interpretable y menos contaminado por ruido operacional.

7. Análisis exploratorio del dataset resultante

Una vez validado el dataset limpio, se pasó a la fase de análisis exploratorio. Esta etapa tenía una doble finalidad. Por un lado, servir como prueba de que la base ya era coherente y susceptible de ser analizada sin errores estructurales. Por otro, extraer patrones de negocio que ayudasen a decidir cómo construir la fase predictiva. El análisis exploratorio no se entendió, por tanto, como una simple colección de gráficos, sino como un paso de diagnóstico y toma de decisiones muy importantes para las fases posteriores.

El script de exploración generó primero un resumen general del archivo, calculó el número de productos distintos, revisó nulos y obtuvo estadísticos descriptivos básicos. Después construyó una agregación mensual para tres indicadores principales: cantidad total, ventas totales y margen bruto. Sobre esta agregación se representaron series temporales y se elaboraron rankings complementarios por clientes, tipo de cliente y provincia. Esta combinación permitió leer el negocio desde dos ángulos: evolución temporal y estructura comercial.

7.1. Evolución mensual de la demanda agregada

El gráfico de evolución mensual de la cantidad total pone de manifiesto que la demanda no sigue una trayectoria lineal ni homogénea. Aparecen varios picos muy marcados, especialmente al inicio de 2023, a finales de 2023 y en algunos meses concretos de 2024 y 2025. Esto sugiere, y afirmo al habérselo preguntado

a empleados, que el negocio tiene una componente de variabilidad elevada, probablemente vinculada a operaciones de mayor tamaño, campañas comerciales o pedidos puntuales de clientes concretos. Cuando hay mayor volumen de venta es siempre en torno a las navidades.

Desde la perspectiva de ingeniería del dato, este hallazgo es importante porque justifica la necesidad de trabajar con técnicas que capturen memoria temporal e inercia reciente. Si la demanda fuera completamente estable, un modelo naïve sería suficiente. Sin embargo, la propia serie sugiere que hay cambios de ritmo que exigen una representación temporal más rica.




Figura 1. Evolución mensual de la cantidad total.

7.2. Evolución mensual de las ventas totales

La trayectoria de las ventas totales confirma la irregularidad observada en la cantidad, aunque además muestra una fuerte concentración de facturación en determinados meses. Destacan dos picos muy acusados, uno a finales de 2023 y otro a finales de 2024, que elevan de forma notable el total facturado respecto al resto del periodo. Este patrón tiene una lectura clara de negocio: una parte importante del volumen anual parece depender de operaciones de importe elevado más que de una repetición perfectamente uniforme mes a mes.

Para la fase posterior de análisis del dato, esta observación es muy relevante porque la variable ventas no funciona solo como descriptor económico, sino también como señal temporal auxiliar para explicar futuras cantidades. Por eso, en la fase de modelización se incorporaron retardos y medias móviles de ventas junto con las de demanda.





Figura 2. Evolución mensual de las ventas totales.

7.3. Evolución mensual del margen sobre registros con coste analítico informado

La interpretación del margen bruto requirió una revisión específica durante la validación del dataset, ya que su lectura sobre el conjunto completo podía resultar distorsionada por la disponibilidad desigual del coste analítico. Por este motivo, la representación final del margen se realizó únicamente sobre los registros que sí disponían de coste analítico informado, con el fin de obtener una aproximación más consistente a esta variable.

Desde el punto de vista metodológico, esta decisión permitió conservar el valor analítico del margen como indicador económico, pero evitando interpretaciones erróneas sobre la totalidad del dataset. Así, mientras que las ventas siguen aportando una medida global del volumen monetario comercializado, el margen pasa a leerse como una referencia financiera útil solo en aquellos casos en los que la información de coste está correctamente informada. De este modo, el análisis mantiene una dimensión económica relevante, aunque con un alcance más prudente y metodológicamente controlado.



• Figura 3. Evolución mensual del margen sobre registros con coste analítico informado

7.4. Segmentación por tipo de cliente

El análisis por tipo de cliente añade una capa claramente de negocio al trabajo de ingeniería del dato. El gráfico correspondiente muestra que la mayor parte de las ventas se concentra en hospitales, seguidos a una distancia considerable por particulares, que incluyen perfiles como clínicas, clubes deportivos, mutuas y otros centros privados. Los distribuidores apenas representan una fracción pequeña del total, mientras que una categoría residual de clientes “otros/revisar” recoge casos que fue necesario homogeneizar y clasificar durante la limpieza.

Este resultado es muy útil por dos motivos. Primero, porque confirma que el mercado principal de la empresa es institucional y sanitario, algo coherente con el contexto del proyecto. Segundo, porque sugiere que parte de la volatilidad mensual puede estar asociada a compras hospitalarias de mayor volumen y no tanto a un goteo regular de clientes particulares.




Figura 4. Ventas totales por tipo de cliente.

7.5. Concentración por clientes

La distribución del negocio por clientes confirma un grado de concentración elevado. El ranking de los diez principales clientes por facturación muestra que unos pocos clientes acumulan una porción sustancial del total. Esto tiene implicaciones directas para la analítica: cuando el negocio depende mucho de clientes tractores, las series temporales pueden presentar saltos importantes en determinados meses, asociados a pedidos concretos de esos clientes clave. Este es el ejemplo de un pedido muy grande que hizo el cliente CL0740 en el 2024.

Desde el punto de vista de ingeniería del dato, este hallazgo invita a interpretar con cuidado los picos de la serie. No siempre responden a ruido o errores; en ocasiones reflejan la propia estructura concentrada del negocio. Por eso, la estrategia de limpieza evitó eliminar de forma indiscriminada valores altos que, aunque extremos, podían ser económicamente reales.




Figura 5. Top 10 clientes por facturación.

7.6. Concentración geográfica por provincias

El análisis geográfico revela una concentración territorial muy clara. Madrid aparece como la provincia con mayor volumen de ventas con mucha diferencia sobre el resto, seguida por Barcelona y, ya bastante por detrás, por otras provincias como Cantabria, Cádiz, Sevilla, Bizkaia o Valencia. Esta estructura tiene sentido empresarial, dado el peso asistencial y hospitalario de Madrid, pero además ofrece una lectura operativa: una parte importante del negocio se apoya en un núcleo geográfico muy definido. Por no hablar de que la sede se ubica en Madrid, por lo que es lógico que lidere el ranking.

Aunque esta variable territorial no se utilizó directamente en el modelo final de demanda mensual por producto, sí resulta valiosa para la comprensión global del negocio y podría convertirse en una vía de segmentación futura si se desarrollasen modelos por área geográfica o por cartera comercial.




Figura 6. Top 10 provincias por ventas.

7.7. Síntesis del análisis exploratorio

En conjunto, el análisis exploratorio permitió cerrar varias conclusiones previas a la modelización. La primera es que la demanda y la facturación presentan una alta variabilidad mensual, con episodios de concentración clara. La segunda es que el negocio se apoya principalmente en clientes hospitalarios y en una base geográfica liderada por Madrid. La tercera es que no parecía razonable construir un modelo genérico para todos los productos sin filtrar previamente aquellos con mayor relevancia, ya que gran parte del comportamiento del negocio se concentra en unas pocas referencias y clientes.

Además, el propio proceso exploratorio ayudó a detectar que el gráfico que más sentido tenía conservar como referencia visual en la parte de ingeniería del dato era el de barras horizontales con el Top 10 de productos por suma de Importe ventas (Real) por Descripción trabajado en Power BI. Aunque ese visual no forma parte de los anexos gráficos disponibles en este momento, su elección refuerza la coherencia metodológica del proyecto: en ingeniería del dato interesaba visualizar qué referencias sostienen el negocio antes de pasar a la predicción temporal.

8. Preparación del conjunto analítico para modelización

La transición desde la ingeniería del dato hacia el análisis del dato se realizó seleccionando los quince productos con mayor demanda acumulada. Esta decisión no fue arbitraria. En un contexto con 7.624 registros iniciales y una distribución muy desigual del volumen por producto, focalizar el modelado en los productos realmente relevantes permitía evitar que el aprendizaje quedase dominado por referencias residuales o con histórico demasiado pobre.

La lista de productos seleccionados fue la siguiente: 3667, 3668, 1373_, 3647_, 8381, 3669, FA7501, 4871, 3648, CO14000, 6749_, 1393-NARANJA-PEQ, 3836, 5614_ y 6750_. Una vez aplicado este filtro, la muestra quedó en 411 registros, que después se redujeron a 366 al exigir un histórico mínimo suficiente para construir retardos y medias móviles.

Esta preparación del conjunto analítico incluyó una fase importante de feature engineering temporal: se generó una tendencia interna por producto, retardos de cantidad y ventas a uno, dos, tres y seis meses, medias móviles y desviaciones móviles, y una codificación cíclica del mes mediante seno y coseno. Aunque estas variables pertenecen ya a la fase de análisis del dato, su posibilidad depende por completo de una buena ingeniería previa. Sin una base cronológica limpia y ordenada, no habría sido posible generarlas de forma consistente.

Tabla 3. Productos incluidos en la fase predictiva

Top 15 productos seleccionados para modelización
3667
3668
1373_
3647_
8381
3669
FA7501
4871
3648
CO14000

Top 15 productos seleccionados para modelización
6749_
1393-NARANJA-PEQ
3836
5614_
6750_

9. Discusión metodológica en relación con la rúbrica

Si se contrasta el trabajo realizado con la rúbrica de Ingeniería del Dato, la fase desarrollada se sitúa claramente en la parte alta. En cuanto al origen de los datos, no se parte de un repositorio público homogéneo, sino de una combinación de distintas fuentes internas y de un trabajo manual de depuración e integración. Esto encaja con el nivel más exigente de la rúbrica, que valora la combinación de diferentes repositorios y la elaboración manual del set de datos, junto con transformaciones y limpieza completas.

En lo relativo a limpieza y transformación, la memoria documenta la eliminación de columnas vacías o constantes, la depuración de identificadores de producto inválidos, el tratamiento de nulos, la conversión de tipos y la exclusión de registros con anomalías. No solo existe transformación, sino que además se explica con detalle el motivo de cada decisión. Y en el plano del análisis exploratorio, se han realizado descripciones estadísticas, gráficas temporales y segmentaciones comerciales con interpretación de negocio, es decir, un análisis descriptivo contextualizado y no una simple enumeración de variables.

En otras palabras, la fortaleza de esta fase no está solo en la cantidad de pasos ejecutados, sino en su coherencia con el propósito final del proyecto. Cada transformación se hizo para mejorar la calidad de la base analítica y cada visual se incluyó porque ayudaba a entender mejor el comportamiento del negocio o a justificar la estrategia de modelización posterior.

9.1. Relación entre la ingeniería del dato y el valor de negocio

En el mismo sentido, ordenar el dataset por producto y fecha no fue una cuestión estética, sino una validación funcional del orden temporal. Las variables creadas en la siguiente fase: retardos, medias móviles y tendencia interna, dependen completamente de que ese orden sea correcto. Un pequeño error en la secuencia de fechas habría generado variables aparentemente válidas, pero como concepto erróneas. Por eso, en esta

memoria se considera que la validación forma parte de la ingeniería del dato con la misma importancia que la limpieza.

Más allá de la limpieza visible, la fase incluyó varios controles de validación que son fundamentales, aunque a veces queden menos reflejados en un resumen superficial. Se comprobó la existencia real del archivo de entrada, se revisó la estructura de columnas, se inspeccionó el número de registros y se verificó la correspondencia entre tipos de dato esperados y tipos obtenidos. También se revisó la distribución de nulos y se efectuó una lectura explícita de los flags de ventas cero y margen negativo. Estos pasos son relevantes porque una base puede parecer correcta a simple vista y, sin embargo, contener incoherencias que rompen el análisis posterior.

9.2. Controles de validación y coherencia del dato

Este criterio está alineado con el tipo de preguntas que el TFG intenta responder. Si el interés principal es anticipar demanda para orientar compras, planificación y seguimiento comercial, la lectura mensual tiene mucho más sentido que una lectura extremadamente granular difícil de mantener. Además, la posterior creación de lags, medias móviles y particiones temporales se vuelve más interpretable sobre una base mensual. La serie deja de ser una sucesión caótica de movimientos pequeños y pasa a convertirse en una secuencia económica legible, donde pueden identificarse subidas, caídas, concentraciones puntuales y ritmos de reposición.

Una de las decisiones metodológicas más importantes de toda la fase fue trabajar con una unidad de análisis mensual por producto. Esta elección simplifica la serie respecto al detalle transaccional, pero no debe interpretarse como una pérdida gratuita de información. En realidad, responde a un equilibrio entre dos necesidades distintas. Por un lado, la empresa necesitaba un enfoque que ayudase a planificar y comparar tendencias con lógica operativa. Por otro, el histórico disponible en muchas referencias no permitía sostener un modelo robusto a una frecuencia demasiado fina. La agregación mensual permitió estabilizar parte del ruido y construir patrones comparables entre productos.

9.3. Justificación de la agregación mensual y de la unidad de análisis

Además, la fase permitió dejar claramente diferenciadas las capas de trabajo: fuente original, transformación intermedia, dataset limpio y conjunto preparado para modelización. Esta jerarquía evita confusiones entre versiones, reduce el riesgo de trabajar con archivos equivocados y facilita el control de cambios cuando se incorporan ajustes posteriores. Desde la perspectiva de un TFG, esta organización también mejora la defensa oral del proyecto, porque permite explicar con claridad qué parte del dato se toma como origen, qué parte se transforma y qué parte llega realmente al modelo analítico.

Otro aspecto que merece destacarse es la reproducibilidad del proceso. La fase de ingeniería del dato no se limitó a una limpieza puntual realizada una sola vez, sino que quedó traducida en scripts y pasos trazables que pueden repetirse. El archivo de entrada, las rutas de trabajo, la secuencia de filtros, la exportación del dataset limpio y la generación de salidas gráficas están descritos de forma suficiente como para rehacer el proceso sin depender de una memoria informal como lo es esta. Esta trazabilidad tiene un valor académico evidente, pero también un valor profesional muy alto, porque convierte el trabajo en un pequeño sistema de datos mantenible a lo largo del tiempo. En proyectos empresariales reales, la diferencia entre un análisis útil y un análisis frágil suele estar precisamente ahí, en la capacidad para repetirlo, revisarlo y actualizarlo sin empezar desde cero cada vez.

9.4. Reproducibilidad, trazabilidad y valor metodológico de la fase

La fase de ingeniería del dato desarrollada en este trabajo se ha planteado con un enfoque reproducible y trazable, de manera que el proceso seguido pueda repetirse en futuras actualizaciones del proyecto. Para ello, se ha trabajado con scripts estructurados en Python, donde quedan definidos de forma explícita los pasos de carga, limpieza, transformación, filtrado y generación del dataset analítico final. Esto permite que la preparación del dato no dependa de acciones manuales aisladas, sino de un flujo ordenado y replicable.

La trazabilidad se garantiza porque cada decisión adoptada durante esta fase puede seguirse y justificarse: desde la selección de las fuentes iniciales hasta la definición de la unidad de análisis, el tratamiento de nulos, la eliminación de variables no informativas y la creación de una base limpia y consistente para el análisis posterior. De este modo, no solo se dispone de un resultado final, sino también de un proceso transparente y coherente que explica cómo se ha llegado a él.

Desde el punto de vista metodológico, esta fase tiene un valor fundamental dentro del TFG, ya que ha permitido construir una base sólida sobre la que apoyar tanto el análisis exploratorio como la modelización predictiva. En consecuencia, la ingeniería del dato no se ha limitado a una tarea técnica previa, sino que ha constituido un elemento esencial para garantizar la calidad, la consistencia y la utilidad del trabajo analítico posterior.

10. Limitaciones de la fase

Como toda fase de ingeniería del dato aplicada a información real de empresa, este trabajo también presenta limitaciones. La principal tiene que ver con la disponibilidad y estructura original de los datos. Al tratarse de exportaciones operacionales, algunas columnas no estaban pensadas para análisis predictivo y otras llegaban con nombres o formatos poco homogéneos. Esto obligó a realizar limpieza manual y a renunciar a parte de la información original que no aportaba valor.

Una segunda limitación es la agregación temporal. Trabajar a nivel mensual por producto resulta adecuado para una primera aproximación de demanda, pero sacrifica parte del detalle transaccional de línea de factura. Futuras versiones del proyecto podrían explorar una granularidad semanal o incluso diaria en algunos productos, siempre que el histórico lo permita.

Otra de las limitaciones detectadas en esta fase estuvo relacionada con la cobertura de la información de coste analítico. Esta circunstancia condicionó el uso del margen bruto como indicador general sobre la totalidad del dataset, por lo que se optó por representarlo únicamente sobre los registros que sí disponían de dicho dato.

Por último, la fase exploratoria ha servido para identificar patrones claros, pero no agota la riqueza del negocio. Existen variables potencialmente relevantes —por ejemplo, vendedor, tipo de centro o combinaciones de producto— que podrían desarrollarse en una ampliación futura del modelo de datos.

11. Conclusiones

La fase de ingeniería del dato permitió transformar un conjunto heterogéneo de ficheros empresariales en una base analítica limpia, coherente y orientada a predicción. A lo largo del proceso se combinaron decisiones de depuración en Power Query y Power BI con un tratamiento reproducible en Python, lo que hizo posible controlar la calidad del dato, justificar la eliminación de variables irrelevantes y construir un dataset mensual por producto útil para el análisis posterior.

El análisis exploratorio derivado de esta base mostró que el negocio presenta una demanda irregular, una facturación concentrada en determinados meses, un peso dominante del segmento hospitalario y una fuerte concentración geográfica en la comunidad de Madrid. Estas conclusiones no solo describen el negocio, sino que explican por qué fue necesario trabajar con variables temporales y con una selección de productos relevantes en la fase de modelización.

En definitiva, no has sido una etapa auxiliar, sino un bloque central del proyecto. Gracias a esta fase, la parte de análisis del dato pudo apoyarse en una base robusta, trazable y alineada con los objetivos reales del TFG.

Por ejemplo, eliminar columnas constantes o totalmente vacías reduce ruido y mejora la interpretación del modelo, pero también evita dedicar tiempo a variables sin sentido económico. Del mismo modo, depurar productos sin identificador válido no solo mejora la tabla de dimensiones, sino que impide que una misma referencia aparezca fragmentada en distintos códigos, algo que distorsionaría el análisis comercial y la predicción. Incluso la exploración por clientes, provincias y tipos de cliente cumple una función que va más allá de lo descriptivo, ayuda a comprender de dónde vienen los picos de la serie y, por tanto, por qué algunos meses no pueden interpretarse como meras anomalías estadísticas.

Una fortaleza adicional del trabajo es que la ingeniería del dato no se diseñó al margen del negocio. Desde el principio, las decisiones de transformación se orientaron a construir una base útil para responder preguntas reales como: qué referencias concentran el volumen, cómo se comporta la demanda en el tiempo, qué clientes sostienen la facturación y qué estructura mínima necesita un modelo predictivo para funcionar. Esta orientación es importante porque evita una práctica bastante común en proyectos académicos la cual es limpiar datos por inercia técnica sin vincular la limpieza a un propósito claro. Aquí sucede lo contrario. Cada paso de depuración tiene una traducción práctica y con total sentido dentro del proyecto.

12. Bibliografía

- Microsoft. (2026). *Documentación de Power BI*. Microsoft Learn. <https://learn.microsoft.com/es-es/power-bi/>
- OpenAI. (2026). *ChatGPT*. OpenAI Help Center. <https://help.openai.com/en/collections/3742473-chatgpt>
- Pandas development team. (2026). *pandas documentation*. PyData. <https://pandas.pydata.org/docs/>
- Python Software Foundation. (2026). *Python documentation*. <https://docs.python.org/>
- scikit-learn developers. (2026). *scikit-learn documentation*. <https://scikit-learn.org/stable/>
- The Matplotlib development team. (2026). *Matplotlib documentation*. <https://matplotlib.org/stable/>
- XGBoost contributors. (2026). *XGBoost documentation*. <https://xgboost.readthedocs.io/>

Declaración de uso de herramientas de inteligencia artificial

Durante la elaboración de esta memoria y del código de Python se ha utilizado ChatGPT, de OpenAI, como herramienta de apoyo puntual para la mejora de la redacción, la reformulación de algunos fragmentos, la organización de ideas y la revisión formal del texto. En ningún caso esta herramienta ha sustituido el análisis propio, la interpretación de resultados, la selección metodológica ni la elaboración de las conclusiones, que han sido realizadas y revisadas críticamente por el autor.

9.4. Reproducibilidad, trazabilidad y valor metodológico de la fase

Anexo A. Variables del dataset limpio

Variable	Descripción funcional
Año	Referencia temporal anual
Año_mes	Etiqueta del periodo mensual
Fecha_Mes	Fecha normalizada del mes
N_producto	Identificador del producto
Cantidad_Total	Cantidad agregada por producto y mes
Ventas_Totales	Importe total de ventas agregado
Coste_Total_Analitico	Coste analítico asociado al periodo
Margen_Bruto	Margen bruto del registro agregado
Margen_Porcentaje	Margen relativo
Flag_Anomalia_Comercial	Indicador de registro comercial anómalo
Flag_Margen_Negativo	Indicador de margen negativo
Flag_Ventas_Cero	Indicador de ventas nulas
Mes_Num	Mes en formato numérico
Tipo_Registro	Clasificación del registro

Anexo B. Gráfico exploratorio de referencia validado en Power BI

Durante la fase exploratoria se compararon distintas visualizaciones para decidir cuál resumía mejor la lógica de negocio de la empresa. Finalmente se seleccionó un gráfico de barras horizontales con el Top 10 de productos por suma de Importe ventas (Real) por Descripción. Esta visualización aporta una ventaja relevante frente a los rankings por código de producto: permite relacionar directamente el volumen de facturación con una lectura comprensible del catálogo, facilitando la interpretación ejecutiva del resultado.

El gráfico confirma, además, una fuerte concentración de ingresos en un número reducido de referencias. El módulo ECG de 12 canales aparece claramente destacado como el producto con mayor peso en ventas reales, seguido por el transductor de presión para tablet Mesi y por un conjunto reducido de equipos de electroterapia, diagnóstico y ergometría. Desde la perspectiva de ingeniería del dato, esta figura resume por qué resultaba necesario construir una base mensual limpia y trazable: la empresa no vende un catálogo homogéneo, sino una combinación de referencias con pesos económicos muy distintos.




Figura A1. Top 10 productos por suma de Importe ventas (Real) por Descripción.

Por su valor explicativo, esta visualización se conserva como gráfico de referencia para la memoria y para la futura presentación del TFG. No sustituye a los gráficos agregados de cantidad, ventas o margen, pero sí

complementa el análisis exploratorio mostrando qué productos concretos sostienen una parte sustancial de la facturación.

Anexo C. Tablas de apoyo al análisis exploratorio

A continuación, se incluyen las tablas de salida más relevantes del proceso exploratorio. No se incorporan todas las tablas generadas por los scripts, sino aquellas que ofrecen una lectura útil del negocio y justifican la posterior selección de variables y productos.

Tipo de cliente	Ventas totales	Cantidad total	Nº clientes	Ticket medio
HOSPITAL	11.431.593,27	127.841	311	855,08
PARTICULAR	7.333.652,15	44.647	557	1.182,47
OTROS_REVISAR	782.501,30	7.512	40	899,43
DISTRIBUIDOR	74.454,20	81	7	979,66

Tabla C1. Resumen de ventas por tipo de cliente.

La tabla refuerza la conclusión visual del gráfico principal: el segmento hospitalario concentra la mayor parte del ingreso total, mientras que particulares ocupan una segunda posición importante y distribuidores tienen un peso muy reducido.

Cliente	Ventas totales	Cantidad total	Nº operaciones
CL0740	1.666.730,94	5.070	57
CL0295	1.397.898,07	5.501	57
CL0050	996.713,98	6.610	573
CL0143	525.187,32	301	239
CL0013	516.220,66	2.339	338
CL0154	488.970,13	24.595	106
CL0043	429.426,89	1.101	385
CL0048	275.180,78	4.496	731
CL0339	227.068,13	225	81
CL0004	218.887,38	519	172

Tabla C2. Top 10 clientes por facturación.

La concentración en un número reducido de clientes ayuda a explicar determinados picos de facturación mensual y subraya la necesidad de interpretar la serie temporal con contexto comercial.

Provincia	Ventas totales	Cantidad total	Nº clientes
MADRID	8.068.479,54	53.708	202
BARCELONA	1.988.309,22	25.515	114
CANTABRIA	647.676,15	25.157	16
CADIZ	590.998,78	2.539	13
SEVILLA	590.266,64	1.727	32
BIZKAIA	555.066,95	1.342	31
VALENCIA	522.502,82	17.413	42
ASTURIAS	451.033,41	1.502	23
BADAJOS	357.855,34	1.367	9
MURCIA	308.063,78	4.276	30

Tabla C3. Top 10 provincias por ventas.

Madrid y Barcelona lideran claramente el mapa comercial, lo que sugiere que la lectura territorial del negocio también puede ser útil en desarrollos analíticos posteriores.

Producto	Cantidad total
3667	39.280
3668	34.010
1373_	11.968
3647_	8.177
8381	5.133
3669	5.118
FA7501	4.884
4871	3.500
3648	3.240
CO14000	2.757

Tabla C4. Top 10 productos por cantidad total acumulada.

Producto	Ventas totales
8381	1.380.000,00
14051	814.375,34
CO14000	723.086,04
CO7500	592.573,15
14188	546.095,06
4938_	468.865,89
FA7501	450.789,80
10601	408.397,77
3846	364.132,27
CO11802	355.518,93

Tabla C5. Top 10 productos por ventas totales acumuladas.

La comparación entre cantidad y ventas acumuladas muestra que no siempre las referencias más rotadas coinciden con las más valiosas en términos monetarios. Esta diferencia fue una de las razones para distinguir claramente demanda, ventas y margen durante la fase de preparación del dato.